

AGEX Billing & Entitlement Architecture

S-06. AGEX Billing, Metering, Subscription & Entitlement 공식 명세

문서 등급: Commercial Platform & Runtime Control Specification

상위 문서: AGEX Master Specification

연계 문서: Business Model / Marketplace / Usage / API Specification / IAM / Multi-Tenant Architecture / Governance / Administrator Guide

상태: 공식 기준안

1. 문서 목적

본 문서는 AGEX의 Subscription, Plan, Price, Meter, Usage, Entitlement, Billing Ledger, Invoice, Marketplace Purchase 및 Tenant Commercial State를 실제 제품과 Runtime에 연결하기 위한 공식 Architecture를 정의한다.

AGEX Billing은 단순 결제 모듈이 아니다.

AGEX는 다음 비용 구조를 가진다.

- Platform Subscription
- Runtime Execution
- Model Usage
- Plugin Usage
- Knowledge Processing
- Memory Storage
- Dedicated Infrastructure
- Marketplace Purchase
- Support
- Enterprise License

따라서 실제 상용화를 위해서는 반드시 다음 질문에 명확한 답이 있어야 한다.

- Tenant가 어떤 기능을 계약상 사용할 수 있는가.
- 어떤 Usage를 어떻게 측정하는가.

- 동일 실행의 Usage가 중복 청구되지 않는가.
- BYOK Model과 AGEX Managed Model 비용을 어떻게 구분하는가.
- Marketplace 구매와 Plugin Permission을 어떻게 구분하는가.
- Plan 변경이 기존 Resource에 어떤 영향을 주는가.
- Billing 문제가 Security Suspension과 어떻게 다른가.
- Usage Event를 어떻게 Invoice로 변환하는가.
- Dedicated/Private Deployment는 어떻게 과금하는가.
- Publisher에게 어떻게 정산할 수 있는가.
- Entitlement가 왜 Permission이 아닌가.

본 문서는 이 전체 구조의 공식 기준이다.

2. 공식 정의

AGEX Billing & Entitlement Architecture는 Tenant가 계약상 사용할 수 있는 Platform Capability를 Entitlement로 정의하고, 실제 Runtime·Model·Plugin·Storage 사용량을 Metering하여 Rating·Ledger·Invoice로 변환하되, Commercial 권리와 Security Permission을 엄격히 분리하는 AGEX의 공식 상용화 제어 구조이다.

3. 가장 중요한 원칙

공식적으로 다음을 절대 구분한다.

Entitlement

≠

Permission

≠

Usage

≠

Billing

각 의미는 다음과 같다.

Entitlement

계약상 해당 기능을 사용할 자격이 있는가.

Permission

현재 Principal이 실제 행동을 수행할 보안 권한이 있는가.

Usage

실제로 얼마나 사용했는가.

Billing

사용량과 계약 조건을 금액으로 계산하는 과정.

4. Entitlement와 Permission

예:

Enterprise Plan이 Private Marketplace 기능을 포함한다.

그러면:

Enterprise Subscription

→ Private Marketplace Entitlement

가 생긴다.

하지만 Tenant 일반 User가 Marketplace 관리자 권한을 자동으로 얻는 것은 아니다.

실제 사용 조건:

Entitlement

∩

IAM Permission

∩

Policy

∩

Tenant State

을 모두 통과해야 한다.

5. Marketplace 구매와 Runtime Permission

마찬가지로:

Plugin Purchase

→ Entitlement

→ Installation 가능

이지:

Plugin Purchase

→ 자동 실행 Permission

이 아니다.

정확한 흐름:

Marketplace Order

→ Entitlement

→ Plugin Installation

→ Enable

→ IAM / Policy

→ Runtime Execution


6. 전체 Architecture

Product Catalog

|



Plan



Invoice

|



Payment / Settlement

7. Billing Domain의 책임

본 Domain은 다음을 담당한다.

- Product Catalog
- Plan
- Price
- Subscription
- Entitlement
- Meter
- Usage Record
- Rating
- Billing Ledger
- Invoice
- Credit / Adjustment
- Marketplace Commercial Record
- Publisher Settlement
- Billing State

8. Billing Domain이 하지 않는 것

다음은 Billing이 담당하지 않는다.

- Authentication

- Authorization
- Tenant Security
- Runtime Permission
- Plugin Action Permission
- Model Data Policy
- Governance Approval

즉 Billing이 다음을 반환할 수는 있다.

feature_enabled = true

그러나:

action_authorized = true

를 결정하지 않는다.

9. 공식 핵심 Resource

최소 다음 Resource를 정의한다.

Product

Plan

Price

Offer

Subscription

Entitlement

Meter

UsageRecord

RatingRecord

BillingAccount

BillingLedgerEntry

Invoice

InvoiceLine

Credit

Adjustment

Order

Settlement

Marketplace와 연계 시:

Listing

Offer

Order

Entitlement

관계를 사용한다.

10. Product

Product는 상업적으로 판매 가능한 Capability Group이다.

예:

- AGEX Platform
- Dedicated Runtime
- Private Marketplace
- Premium Support

Product 자체는 가격을 의미하지 않는다.

11. Product Resource 예

kind: Product

metadata:

id: prd_xxx

specification:

code: AGEX_PLATFORM

name: AGEX Platform

status: ACTIVE

12. Plan

Plan은 Product Capability와 기본 Entitlement 묶음이다.

예:

- Developer
- Team
- Business
- Enterprise
- Dedicated

이 명칭은 상품 전략에 따라 변경될 수 있다.

Architecture는 명칭에 종속되지 않는다.

13. Plan Resource

예:

kind: Plan

specification:

product_id: prd_xxx

entitlements:

- feature: AGENT_RUNTIME
- feature: WORKFLOW
- feature: KNOWLEDGE

limits:

- meter: EXECUTION_CREDIT
- included: 10000

14. Price

Price는 Plan 또는 Offer의 금전적 조건이다.

Price와 Plan을 분리한다.

이유:

동일 Plan에 다음이 존재할 수 있기 때문이다.

- Monthly
- Annual
- Region-specific
- Currency-specific
- Enterprise negotiated price

15. Price Type

지원 가능:

FIXED

USAGE_BASED

TIERED

VOLUME

PACKAGE

CUSTOM

16. Money Type

금액은 Float를 사용하지 않는다.

공식 형태:

```
{  
  "amount": "120.0000",  
  "currency": "USD"  
}
```

또는 Minor Unit 모델도 사용할 수 있다.

한 방식으로 통일한다.

17. Offer

Offer는 특정 고객/시장/Marketplace에서 실제로 제시되는 상업 조건이다.

Product

→ Plan

→ Price

→ Offer

Offer는 할인, Commitment, 기간 등을 포함할 수 있다.

18. Subscription

Subscription은 Tenant와 Plan 간 계약 관계다.

Tenant

→ Subscription

→ Plan

19. Subscription 기본 필드

subscription_id

tenant_id

plan_id

price_id

state

started_at

current_period_start

current_period_end

cancel_at

ended_at

20. Subscription State

공식 기본 상태:

TRIALING

ACTIVE

PAST_DUE

RESTRICTED

CANCEL_SCHEDULED

CANCELLED

ENDED

Security 상태와 혼용하지 않는다.

21. Billing Restricted

RESTRICTED는 상업적 제한 상태다.

예:

- 신규 Resource 생성 금지
- 신규 고비용 Execution 제한
- Read/Export 허용

Security Suspension과 다르다.

22. Security Suspension과 차이

Billing Restricted

≠

Security Suspended

Security 사고가 있으면 Billing 상태와 관계없이 Runtime을 즉시 차단할 수 있다.

반대로 결제 지연을 이유로 Security Incident State를 사용하지 않는다.

23. Subscription Snapshot

Invoice 재현성을 위해 Billing Period마다 사용된:

- Plan Version
- Price
- Discount
- Currency
- Included Usage

를 Snapshot할 수 있어야 한다.

나중에 Plan이 변경되어도 과거 Invoice가 바뀌지 않아야 한다.

24. Entitlement

Entitlement는 Tenant가 사용할 수 있는 Capability를 표현한다.

예:

AGENT_RUNTIME

WORKFLOW

ADVANCED_GOVERNANCE

PRIVATE_MARKETPLACE

DEDICATED_RUNTIME

PRIVATE_MODEL

25. Entitlement Resource

예:

kind: Entitlement

specification:

tenant_id: ten_xxx

feature_code: PRIVATE_MARKETPLACE

source_type: SUBSCRIPTION

source_id: sub_xxx

state: ACTIVE

valid_until: null

26. Entitlement Source

Entitlement는 여러 Source에서 생성될 수 있다.

SUBSCRIPTION

MARKETPLACE_ORDER

MANUAL_GRANT

ENTERPRISE_CONTRACT

TRIAL

PROMOTION

Manual Grant는 Governance/Audit가 필요하다.

27. Entitlement State

ACTIVE

SCHEDULED

EXPIRED

REVOKED

SUSPENDED

28. Feature Availability

Application 또는 Platform은 기능 제공 전에:

Entitlement Check

를 수행할 수 있다.

예:

Private Marketplace UI

는 Entitlement가 없는 Tenant에는 비활성화할 수 있다.

하지만 실제 API는 다시 IAM을 검증해야 한다.

29. Entitlement Cache

성능상 Cache할 수 있다.

Cache Key:

tenant

feature

subscription_version

Plan 변경이나 Revocation 시 빠르게 무효화되어야 한다.

30. Limit과 Entitlement

Entitlement가 기능 사용 가능 여부라면 Limit은 사용 범위를 정의한다.

예:

AGENT_RUNTIME = enabled

CONCURRENT_EXECUTIONS = 20

31. Quota와 Billing Limit

Quota는 Runtime Control에서 사용한다.

Billing Plan의 Limit이 Quota 정책으로 변환될 수 있지만 두 Domain은 분리한다.

구조:

Plan Limit

→ Entitlement/Quota Configuration

→ Runtime Enforcement

32. Usage Metering

Usage는 실제 사용 사실을 기록한다.

예:

- Model Token
 - Execution Duration
 - Plugin Call
 - Storage
 - Retrieval
 - GPU Time
-

33. Usage Record

Canonical 최소 필드:

usage_id

tenant_id

execution_id

resource_type

resource_id

usage_type

quantity

unit

occurred_at

idempotency_key

provider_id

model_id

필요 시:

billing_account_id

cost_basis

region

를 추가한다.

34. Usage Type

공식 초기 Vocabulary 예:

EXECUTION

RUNTIME_SECOND

MODEL_INPUT_TOKEN

MODEL_OUTPUT_TOKEN

MODEL_REQUEST

PLUGIN_CALL

KNOWLEDGE_STORAGE_BYTE_HOUR

KNOWLEDGE_RETRIEVAL

MEMORY_STORAGE_BYTE_HOUR

GPU_SECOND

ARTIFACT_STORAGE_BYTE_HOUR

35. Internal Meter와 External Pricing Meter

매우 중요한 원칙이다.

내부적으로는 세부 Metric을 많이 측정해도 된다.

하지만 고객에게 모든 Metric을 가격 단위로 노출하지 않는다.

예:

내부:

CPU second

RAM GB-second

queue time

model tokens

plugin calls

외부:

Execution Credits

Managed Model Usage

Storage

로 단순화할 수 있다.

36. Meter

Meter는 Usage Record를 청구 가능한 단위로 집계하는 규칙이다.

예:

Meter: MODEL_INPUT_TOKEN

Unit: 1M tokens

또는:

Meter: EXECUTION_CREDIT

37. Meter Resource

필드:

meter_id

usage_type

aggregation

unit

window

filters

38. Meter Aggregation

지원 가능:

SUM

COUNT

MAX

AVERAGE

UNIQUE_COUNT

Billing에는 주로 SUM/COUNT를 사용한다.

39. Usage Idempotency

동일 Logical Usage가 중복 기록되지 않아야 한다.

특히 다음 상황을 고려한다.

- Queue Redelivery
 - Provider Retry
 - Event Replay
 - Webhook Retry
 - Runtime Recovery
-

40. Provider Retry와 Usage

Model Request가 Fallback되어 2개 Provider Call이 발생하면:

Logical Model Request = 1

Actual Provider Calls = 2

둘을 구분한다.

실제 비용이 두 번 발생했다면 Cost Record에는 두 Attempt가 들어갈 수 있다.

41. Usage Event Source

Usage는 가능한 Runtime/Provider Gateway에서 공식 Event로 생성한다.

Application이 임의로 "100 tokens 썼다"고 보내는 값을 Billing Source of Truth로 사용하지 않는다.

42. Usage Immutability

확정된 Usage Record는 직접 수정하지 않는 것을 원칙으로 한다.

오류가 있으면:

Adjustment

를 생성한다.

43. Rating

Rating은 Usage를 Price Rule에 따라 금액으로 계산하는 과정이다.

Usage

×

Price Rule

=

Rated Charge

44. Rating Record

예:

rating_id

usage_id / aggregation_window

price_id

quantity

unit_price

amount

currency

rated_at

45. Price Snapshot

Rating 시점의 Price 정보를 Snapshot한다.

나중에 Price가 바뀌어도 과거 Charge는 변경되지 않는다.

46. Included Usage

Plan에는 기본 포함량이 존재할 수 있다.

예:

10,000 Execution Credits included

Rating:

Usage

→ Included Allowance

→ Overage

47. Overage

포함량을 초과한 사용량에 대해 별도 Price를 적용한다.

48. Tiered Pricing

예:

0 ~ 10,000 included

10,001 ~ 100k rate A

100k+ rate B

Tier 계산 규칙을 명시적으로 정의한다.

49. Minimum Commitment

Enterprise 계약에서는 다음 형태를 지원할 수 있다.

Annual Minimum Commitment

+

Included Usage

+

Overage

50. Prepaid Credit

일부 상품에서 선불 Credit을 지원할 수 있다.

Credit과 현금 Balance를 구분한다.

51. Credit Resource

필드:

credit_id

tenant_id

amount / units

currency or meter

valid_from

expires_at

source

remaining

52. Credit Expiration

만료 정책은 계약에 따라 정의한다.

소급 변경하지 않는다.

53. Billing Ledger

Ledger는 Billing의 공식 회계성 Source of Truth다.

Usage Record 자체가 Invoice가 아니다.

구조:

Usage

→ Rating

→ Ledger

→ Invoice

54. Ledger Entry

예:

ledger_entry_id

billing_account_id

entry_type

amount

currency

reference

occurred_at

posted_at

55. Ledger Entry Type

예:

CHARGE

CREDIT

ADJUSTMENT

REFUND

TAX

DISCOUNT

COMMITMENT

56. Ledger Immutability

Posted Entry를 직접 삭제·수정하지 않는다.

오류는 반대 방향 Adjustment Entry로 정정한다.

57. Billing Account

Tenant와 청구 주체가 항상 1:1일 필요는 없다.

대기업에서:

Billing Account

└─ Tenant A

└─ Tenant B

└─ Tenant C

구조를 지원할 수 있다.

58. Billing Account Resource

필드:

billing_account_id
customer_reference
currency
billing_cycle
payment_terms
state

59. Tenant와 Billing Account

기본은 1:1 가능.

Enterprise에서는 여러 Tenant가 하나의 Billing Account를 공유할 수 있다.

60. Invoice

Invoice는 Billing Period의 최종 청구 문서다.

구성:

Platform Subscription

Runtime Usage

Managed Model

Marketplace

Dedicated Infrastructure

Support

Tax

Credits

61. Invoice State

DRAFT

OPEN

PAID

PAST_DUE

VOID

UNCOLLECTIBLE

실제 결제 시스템과 연계 시 확장 가능.

62. Invoice Line

최소:

invoice_line_id

description

meter / product

quantity

unit_price

amount

currency

period

reference

63. Invoice Reconciliation

Invoice 총액은 Ledger와 재조정 가능해야 한다.

Invoice Total

=

Relevant Posted Ledger Entries

64. Invoice 수정

발행 후 직접 수정하는 대신:

- Credit Note
- Adjustment
- Revised Invoice

등 공식 방법을 사용한다.

65. Tax

세금 계산은 국가/사업 구조에 따라 외부 Tax Provider 또는 별도 모듈을 사용할 수 있다.

AGEX Core Runtime의 책임이 아니다.

66. Payment

Payment Provider는 Billing Domain 외부 Integration으로 취급한다.

Architecture:

Invoice

→ Payment Service

→ Payment Result

→ Billing State Update

67. 결제 실패

결제 실패 즉시 Tenant 데이터를 삭제하지 않는다.

정책 예:

PAST_DUE

→ grace period

→ RESTRICTED

→ cancellation

68. Downgrade

Plan Downgrade 시 현재 Resource가 신규 Limit을 초과할 수 있다.

예:

기존 Agent 100개

신규 Plan Limit 20개

즉시 80개를 삭제하지 않는다.

69. Downgrade 공식 원칙

가능한 Flow:

Downgrade Scheduled

→ Identify Over-limit Resources

→ Notify

→ New Creation Restricted

→ Grace Period

→ Customer Action

70. Upgrade

Upgrade는 다음을 변경할 수 있다.

- Entitlement
- Included Usage
- Quota
- Support Level

하지만:

IAM Permission

을 자동 확대하지 않는다.

71. Plan Change Effective Time

다음 방식 중 계약에 따라 선택한다.

IMMEDIATE

NEXT_BILLING_PERIOD

SCHEDULED_DATE

72. Proration

중간 Upgrade/Downgrade 시 Proration을 지원할 수 있다.

이 계산은 Price/Subscription Domain에서 처리한다.

73. Trial

Trial은 별도 Plan/Subscription State로 운영할 수 있다.

필수 제한:

- Credits
 - Model
 - Runtime
 - Storage
 - Duration
-

74. Trial Abuse 방지

다음과 연계한다.

- Identity
 - Rate Limit
 - Payment verification optional
 - Tenant creation controls
-

75. Free Tier

Free Tier가 있더라도 외부 유료 Provider 호출을 무제한 허용하지 않는다.

76. BYOK Billing

BYOK Model에서는 Provider 사용료를 고객이 직접 부담할 수 있다.

AGEX는 다음에 대해 과금할 수 있다.

- Platform Subscription
- Runtime
- Model Gateway
- Governance
- Observability

BYOK Cost와 Platform Cost를 구분한다.

77. Managed Model Billing

AGEX Managed Model:

Actual Provider Usage

+

Platform/Gateway Pricing

방식을 사용할 수 있다.

단, 사용자에게 Model Cost 구조를 불필요하게 불투명하게 만들지 않는다.

78. Model Cost Pass-Through

Business Model 정책에 따라:

- Pure pass-through
- Markup
- Credit-based abstraction

을 사용할 수 있다.

Architecture는 특정 가격정책에 종속되지 않는다.

79. Private Model Billing

Private Model은 Token보다 다음 Cost Driver가 중요할 수 있다.

- GPU Time
 - Reserved Capacity
 - Dedicated Infrastructure
 - Operations
 - Storage
-

80. Dedicated Runtime

Dedicated Tenant는:

Platform Fee

+

Dedicated Infrastructure

+

Usage

+

Support

구조를 사용할 수 있다.

81. On-Prem / Private Deployment

권장 상용 모델:

Annual Platform License

+

Maintenance / Support

+

Deployment Service

+

Optional Usage-based Components

영구 일회성 설치비만으로 장기 지원하지 않는 것이 좋다.

82. Marketplace Commercial Flow

공식:

Package

→ Listing

→ Offer

→ Order

→ Entitlement

→ Installation

83. Listing

Marketplace에 표시되는 판매 단위다.

Listing 자체가 Package 기술 Source of Truth는 아니다.

84. Marketplace Offer

Offer에는 다음이 포함될 수 있다.

- Price
 - Billing Period
 - Trial
 - Usage Terms
 - Region Availability
-

85. Order

Tenant가 Offer를 획득하는 상업 행위다.

Order 성공 후 Entitlement를 생성한다.

86. Order State

PENDING

CONFIRMED

FAILED

CANCELLED

REFUNDED

87. Order Idempotency

결제/구매 API는 Idempotency가 필수다.

동일 구매 요청이 Network Retry로 2회 청구되지 않도록 한다.

88. Marketplace Subscription

Plugin이 Monthly Subscription 방식일 수도 있다.

이 경우 Platform Subscription과 별도 Commercial Subscription을 둘 수 있다.

89. Plugin Usage Billing

Publisher가 Usage-based Plugin을 판매할 수 있다.

구조:

Plugin Action Usage

→ Meter

→ Rating

→ Publisher Revenue

90. Publisher Settlement

Marketplace에서는 Publisher 정산이 필요하다.

기본:

Gross Transaction

- Platform Commission

- Refund/Adjustment

- Tax/Payment Fee where applicable

=

Publisher Settlement

91. Settlement Resource

필드:

settlement_id

publisher_id
period
gross_amount
commission
adjustments
net_amount
currency
state

92. Commission

Commission은 고정 Architecture 값이 아니다.
Offer/Marketplace Policy로 설정 가능해야 한다.

93. Settlement State

CALCULATING
READY
PAID
HELD
ADJUSTED

94. Refund

Marketplace/Subscription Refund는 Ledger Adjustment로 처리한다.
원 Usage를 삭제하지 않는다.

95. Cancellation

Subscription Cancellation과 Marketplace Entitlement Revoke를 구분한다.

현재 기간 끝까지 사용 가능한지 정책에 따라 결정한다.

96. Entitlement Expiration

Subscription 종료 시 Entitlement도 종료되지만, 즉시 데이터 삭제를 의미하지 않는다.

97. Data Retention after Subscription End

Subscription 종료와 Tenant Data Retention은 별도 정책이다.

Commercial End

≠

Immediate Data Deletion

삭제는 Tenant Lifecycle/Retention 정책을 따른다.

98. Billing State와 Runtime

Runtime은 다음 정보를 사용할 수 있다.

- Entitlement
- Quota
- Billing Restriction

하지만 결제 시스템을 호출할 때마다 Runtime Action을 동기적으로 막는 구조는 피한다.

99. Entitlement Projection

Runtime용 빠른 Projection을 만들 수 있다.

예:

Tenant Entitlement Snapshot

Billing Source of Truth에서 생성한다.

100. Runtime Check

실행 전:

Feature Entitlement

→ Quota

→ IAM Permission

→ Policy

→ Execute

순서로 처리할 수 있다.

정확한 내부 순서는 최적화 가능하지만 의미는 유지한다.

101. Billing 장애 시 Runtime

Billing Service 일시 장애가 모든 Production Execution을 즉시 중단시켜서는 안 된다.

최근 검증된 Entitlement Snapshot을 제한적으로 사용할 수 있다.

102. Fail-Closed vs Grace

Security는 Fail Closed가 기본이지만 Billing은 서비스 연속성을 위해 Grace Policy를 사용할 수 있다.

예:

Entitlement service unavailable

→ use valid recent snapshot

단, 무기한 사용하지 않는다.

103. Quota

Quota Type 예:

CONCURRENT_EXECUTIONS

MONTHLY_EXECUTIONS

MODEL_TOKENS

STORAGE

PLUGIN_CALLS

KNOWLEDGE_SIZE

104. Soft Limit / Hard Limit

Quota에는 두 종류를 지원할 수 있다.

Soft

경고.

Hard

차단.

105. Budget

Budget은 금액 기반 Control이다.

범위:

- Tenant
 - Agent
 - Workflow
 - Model Profile
-

106. Budget State

예:

NORMAL

WARNING

EXCEEDED

107. Budget Action

Policy:

WARN

REQUIRE_APPROVAL

THROTTLE

BLOCK

108. Budget과 Invoice 차이

Budget은 운영 Control.

Invoice는 실제 청구.

Budget ≠ Invoice

109. Usage Attribution

Usage는 최소 Tenant에 귀속해야 한다.

가능하면 추가로:

- Agent
- Workflow
- Execution
- Model
- Plugin
- Cost Center

로 분해한다.

110. Cost Allocation Tag

Resource Labels를 Cost Allocation에 사용할 수 있다.

예:

team

cost_center

project

environment

단, Label 누락으로 Billing 전체가 실패해서는 안 된다.

111. Cost per Execution

공식 계산 예:

Execution Cost

=

Model Cost

+

Runtime Cost

+

Plugin Cost

+

Allocated Infrastructure Cost

내부 Unit Economics에 활용한다.

112. Cost per Successful Task

Business Model에서 정의된 핵심 지표:

Cost per Successful Task

=

Total Relevant Cost

/

Successful Task Count

113. Gross Margin

Gross Margin

=

Revenue

-

Cost of Revenue

Cost of Revenue에는:

- Provider
- Runtime Compute
- GPU
- Storage
- Network
- Support 일부

등이 포함될 수 있다.

114. Rating Time

Usage를:

- Real-time
- Near-real-time

- Batch

중 하나로 Rating할 수 있다.

Architecture는 혼합 방식 지원을 권장한다.

115. Real-Time Rating

Quota/Budget Control에 유용.

하지만 최종 Invoice는 Ledger Reconciliation을 거쳐야 한다.

116. Batch Rating

대규모 Usage 계산에 적합.

117. Late-arriving Usage

Usage Event가 늦게 도착할 수 있다.

지원 정책:

- Current invoice adjustment
- Next invoice adjustment
- Reopen draft period

발행된 Ledger를 직접 수정하지 않는다.

118. Billing Period

기본 예:

MONTHLY

ANNUAL

CUSTOM

Usage Aggregation Window와 Billing Period를 구분한다.

119. Timezone

Billing 계산은 Billing Account 기준 Timezone 또는 UTC 기준으로 명확히 정의한다.
혼용하지 않는다.

120. Currency

Billing Account는 기본 Currency를 가진다.

다중 Currency Invoice를 하나의 Invoice에 혼합하지 않는 것을 권장한다.

121. FX

환율 처리가 필요하면 별도 FX Source와 Snapshot이 필요하다.

MVP Core에는 필수 아님.

122. Discount

지원 가능:

- Percentage
- Fixed
- Volume
- Promotional
- Strategic

할인은 Price 자체를 덮어쓰기보다 별도 Rule로 관리하는 것이 좋다.

123. Enterprise Contract

Enterprise 고객은 Catalog Price가 아니라 Negotiated Offer를 사용할 수 있다.

124. Contract Override

Enterprise Offer는 다음을 Override할 수 있다.

- Price
- Commitment
- Included Usage
- Support
- Dedicated Capacity

Security Baseline은 Override할 수 없다.

125. Billing Governance

다음 변경은 Audit/Governance 대상이다.

- Manual Entitlement Grant
 - Invoice Adjustment
 - Large Credit
 - Price Override
 - Subscription Backdate
 - Settlement Override
-

126. Separation of Duties

가능하면 다음 역할을 분리한다.

Commercial Admin

Billing Operator

Finance Reviewer

Marketplace Operator

한 사람이 모든 Invoice 수정/Settlement까지 무제한 할 수 없게 한다.

127. Billing Audit

반드시 Audit:

- Plan change
- Subscription creation/cancellation
- Entitlement grant/revoke
- Manual credit
- Invoice adjustment
- Marketplace refund
- Publisher settlement change

128. Billing Error

대표 Error Code:

SUBSCRIPTION_NOT_ACTIVE

ENTITLEMENT_REQUIRED

ENTITLEMENT_EXPIRED

QUOTA_EXCEEDED

BUDGET_EXCEEDED

BILLING_ACCOUNT_RESTRICTED

PRICE_NOT_FOUND

RATING_FAILED

INVOICE_NOT_EDITABLE

ORDER_ALREADY_PROCESSED

129. ENTITLEMENT_REQUIRED

이 Error는 Security Permission Denied와 구분한다.

예:

403/feature not entitled

표현은 API Contract에서 최종 확정한다.

130. Usage Pipeline

공식:

Runtime / Model / Plugin

↓

Usage Event

↓

Usage Collector

↓

Deduplication

↓

Meter

↓

Rating

↓

Ledger

↓

Invoice

131. Usage Collector

Collector는 다양한 Source에서 Usage를 받는다.

- Runtime
 - Model Gateway
 - Plugin Runtime
 - Storage
 - Knowledge
-

132. Usage Event Idempotency

Usage Event에는 고유:

usage_event_id

또는 Logical Usage Key가 필요하다.

133. Usage Correction

잘못 수집된 Usage는 원본 삭제보다 Correction Record를 사용한다.

134. Billing Reconciliation

주기적으로 다음을 비교한다.

Runtime Usage

↔ Usage Store

↔ Rating

↔ Ledger

↔ Invoice

불일치 탐지가 필요하다.

135. Provider Cost Reconciliation

Managed Model의 경우 Provider Invoice와 AGEX Usage를 대조할 수 있다.

136. Cost Drift

Provider Price가 변경되면 Cost Profile을 Version 관리한다.

과거 Usage에 새로운 가격을 소급 적용하지 않는다.

137. Price Effective Date

Price에는:

effective_from

effective_to

를 둘 수 있다.

138. Plan Versioning

Plan도 Version 관리한다.

기존 고객을 새 Plan 정의에 조용히 Migration하지 않는다.

139. Grandfathering

기존 고객에게 과거 Price/Plan을 유지할 수 있다.

Subscription Snapshot/Versioning이 필요하다.

140. Billing API

대표 Domain:

/products

/plans

/prices

/subscriptions

/entitlements

/usage

/billing-accounts

/invoices

/orders

/credits

141. Runtime Entitlement API

Runtime은 저지연 Entitlement Check가 필요하다.

Internal API/Projection 사용을 권장한다.

142. SDK

예:

agex.billing.subscriptions

agex.billing.usage

agex.billing.invoices

agex.entitlements

고객 Application SDK에는 필요한 범위만 노출한다.

143. Admin Console

관리 기능:

- Subscription
- Entitlement
- Usage
- Budget

- Invoice
- Credits
- Marketplace Orders

Finance와 Tenant Admin UI를 분리할 수 있다.

144. Tenant Console

Tenant는 자신의:

- Plan
- Usage
- Budget
- Invoice
- Marketplace Purchase

를 조회할 수 있다.

145. Runtime Console

Runtime Operator는 금액보다:

- Quota
- Entitlement
- Budget State

정도만 필요할 수 있다.

146. Notification

알림 예:

- 80% Usage
- Budget Warning

- Credit Low
 - Trial Ending
 - Payment Past Due
 - Entitlement Expiring
-

147. Dunning

결제 실패 후 재청구/알림 절차는 Billing 기능으로 지원할 수 있다.

MVP에서는 외부 Payment Provider에 일부 위임 가능.

148. Marketplace Publisher Dashboard

Publisher가 볼 수 있는 것:

- Sales
- Active Subscriptions
- Usage
- Refunds
- Settlement

다른 Publisher 정보는 볼 수 없다.

149. Billing Security

Billing Data는 민감 Business Data다.

적용:

- Strong IAM
- Tenant Isolation
- Encryption
- Audit

- Least Privilege
-

150. Payment Data

Card Number 등 규제 대상 Payment Data를 AGEX 자체 DB에 직접 저장하지 않는 구조를 권장한다.

외부 인증된 Payment Provider Token을 사용한다.

151. Invoice Privacy

Tenant A가 Tenant B의 Invoice를 조회할 수 없도록 한다.

기본 Multi-Tenant 규칙을 동일하게 적용한다.

152. Billing Admin Access

Global Billing Admin은 상업정보에 접근할 수 있어도 Tenant의 Agent Prompt/Memory를 볼 권한이 자동 생기지 않는다.

153. Fraud / Abuse

다음 이상 징후를 탐지할 수 있다.

- Trial Abuse
- Excessive Usage Spike
- Stolen Credential Model Calls
- Marketplace Purchase Abuse

Security Domain과 연계한다.

154. Usage Spike

비정상 Usage는:

- Cost Anomaly

- Security Incident
- Product Growth

중 무엇인지 구분해야 한다.

155. Hard Stop 주의

Usage 폭증만으로 모든 Runtime을 즉시 종료하기보다 정책에 따라:

warn

throttle

approval

block

을 적용한다.

156. Enterprise Invoice

Enterprise에서는 다음을 지원할 수 있다.

- Purchase Order
- Net Terms
- Annual Commitment
- Manual Invoice

Architecture는 Consumer Card Payment에 종속되지 않는다.

157. Private Deployment License

License Resource를 별도로 만들 수 있다.

예:

license_id

customer

features

capacity

valid_until

signature

158. Offline License

Air-gapped 환경은 Online Entitlement API를 사용할 수 없다.

Signed Offline Entitlement/License Snapshot을 사용할 수 있다.

159. Offline License Security

License Signature 검증이 필요하다.

Tenant/Admin이 License File을 편집해 Entitlement를 확대할 수 없어야 한다.

160. Grace Period

Offline 또는 Billing Dependency 장애 시 Grace Period를 둘 수 있다.

Expiration 후 정책에 따라 제한한다.

161. Usage in Air-Gapped Environment

Usage를 Local Ledger에 기록하고 추후 Export/Report할 수 있다.

계약에 따라 외부 전송 없이 운영 가능해야 한다.

162. Data Portability

Subscription 종료 시 Commercial Resource와 Customer Data Export를 구분한다.

Invoice/Usage 이력은 법적 보존 요구에 따라 Tenant 데이터 삭제와 다른 Retention을 가질 수 있다.

163. Deletion

Tenant Delete 시 Billing Record를 모두 즉시 삭제할 수 없는 경우가 있다.

Accounting/Tax/Legal Retention을 적용할 수 있다.

따라서:

Tenant Operational Data Deletion

≠

Billing Legal Record Deletion

164. Pseudonymization

Tenant 삭제 후 법적 보존이 필요한 Usage/Billing 데이터는 필요한 경우 식별정보를 최소화하거나 Pseudonymize할 수 있다.

165. MVP 범위

Core MVP에서 Billing 전체를 만들 필요는 없다.

초기 필수:

- Plan
- Subscription
- Entitlement
- Basic Quota
- Usage Record
- Model Usage
- Runtime Usage
- Budget Alert 기본
- Admin Usage View

166. MVP에서 제외 가능

- Full Invoice
- Payment Gateway
- Tax
- Publisher Settlement
- Complex Tier Pricing
- Multi-Currency
- Advanced Proration
- Dunning Automation

167. Stage 2

추가:

- Rating
- Billing Ledger
- Invoice
- Credits
- Managed Model Cost
- Enterprise Usage

168. Stage 3

추가:

- Annual Commitment
- Dedicated Runtime Billing
- Enterprise Contract

- Billing Account Hierarchy
 - Advanced Cost Allocation
-

169. Stage 4 Marketplace

필수:

- Marketplace Offer
 - Order
 - Plugin Subscription
 - Publisher Revenue
 - Settlement
 - Refund
-

170. Stage 5

고도화 가능:

- Dynamic Pricing
- Advanced Cost Optimization
- Partner Revenue Share
- OEM Billing
- Embedded Usage Billing

Architecture를 불필요하게 복잡하게 만들지 않는다.

171. MVP End-to-End Scenario

Tenant subscribes to Business Plan

→ Subscription ACTIVE

→ Entitlements generated

- Agent Runtime feature enabled
 - User has agent:execute permission
 - Agent execution
 - Runtime usage recorded
 - Model usage recorded
 - Usage dashboard updated
-

172. Entitlement Denial Scenario

Tenant Plan

- no PRIVATE_MARKETPLACE entitlement

Admin has marketplace permission

- requests private marketplace

Entitlement check

- DENY

IAM Permission이 있어도 사용할 수 없다.

173. Permission Denial Scenario

Tenant has PRIVATE_MARKETPLACE entitlement

- User lacks marketplace:manage

IAM

- DENY

Entitlement가 있어도 실행할 수 없다.

174. Downgrade Scenario

Business

→ Team

Current resources exceed Team limit

→ downgrade scheduled

→ existing resources retained temporarily

→ new creation restricted

→ grace period

즉시 Resource를 삭제하지 않는다.

175. Managed Model Scenario

Agent

→ Model Gateway

→ Managed Provider

→ Provider Usage

→ Usage Record

→ Rating

→ Invoice Line

176. BYOK Scenario

Agent

→ Model Gateway

→ Tenant BYOK

→ Provider charges Tenant directly

AGEX

→ Runtime/Gateway Usage

→ Platform Billing

Provider Cost를 AGEX Managed Model Cost와 구분한다.

177. Marketplace Scenario

Tenant

→ Marketplace Listing

→ Offer

→ Order

→ Entitlement

→ Plugin Installation

→ Admin enables

→ IAM permission

→ Runtime use

→ Plugin usage

→ Publisher settlement

178. Dedicated Enterprise Scenario

Enterprise Contract

→ Dedicated Entitlement

→ Dedicated Runtime allocated

→ Base annual fee

→ reserved infrastructure

→ usage overage

→ invoice

179. Billing Acceptance Criteria

AGEX Billing & Entitlement는 최소 다음을 만족해야 한다.

1. Entitlement와 Permission이 분리된다.
2. Plan과 Price가 분리된다.
3. Subscription이 Tenant에 연결된다.
4. Entitlement Source를 추적할 수 있다.
5. Usage가 Immutable Record로 관리된다.
6. Usage Idempotency가 존재한다.
7. Meter와 Usage Type이 분리된다.
8. Rating이 Price Snapshot을 사용한다.
9. Ledger가 Invoice의 Source of Truth 역할을 한다.
10. Posted Ledger를 직접 수정하지 않는다.
11. Adjustment를 지원한다.
12. BYOK와 Managed Model Billing을 구분한다.
13. Marketplace Order와 Plugin Permission을 구분한다.
14. Plan Upgrade가 IAM 권한을 자동 확대하지 않는다.
15. Downgrade가 Resource를 즉시 삭제하지 않는다.
16. Billing Restricted와 Security Suspended를 구분한다.
17. Tenant Usage를 Resource/Execution 단위로 귀속할 수 있다.
18. Model Fallback 비용을 누락하지 않는다.
19. Billing Record에 Tenant Isolation을 적용한다.

20. Private/On-Prem Commercial Model 확장이 가능하다.

180. 금지사항

다음 구조를 허용하지 않는다.

- Subscription Plan을 IAM Role로 사용
 - Entitlement를 Permission으로 사용
 - Marketplace Purchase 후 자동 Plugin 실행
 - Plan Upgrade 후 자동 Admin Permission 부여
 - Payment Failure를 Security Incident State로 표현
 - Usage Record 직접 수정
 - Posted Ledger Entry 삭제
 - Provider Retry 비용 무시
 - BYOK Provider Cost를 AGEX Managed Cost로 중복 청구
 - Invoice 금액을 Runtime Usage DB에서 즉시 직접 계산
 - Price 변경을 과거 Invoice에 소급
 - Downgrade 시 초과 Resource 즉시 삭제
 - Trial에 무제한 외부 Model 호출 허용
 - Tenant A Billing Data를 Tenant B에 노출
 - Billing Admin에게 Tenant Content 권한 자동 부여
 - Card/Payment Secret을 일반 AGEX Resource에 저장
 - Float로 화폐 계산
 - Marketplace Commission을 Source Code 상수로 고정
 - Enterprise 할인 수동 변경을 Audit 없이 적용
 - Entitlement Service 일시 장애 시 전체 Production 즉시 중단
-

181. Canonical Schema 추가 대상

다음 을 추가한다.

/specs/schemas/billing/

└─ product.schema.json

└─ plan.schema.json

└─ price.schema.json

└─ offer.schema.json

└─ subscription.schema.json

└─ entitlement.schema.json

└─ meter.schema.json

└─ usage-record.schema.json

└─ rating-record.schema.json

└─ billing-account.schema.json

└─ ledger-entry.schema.json

└─ invoice.schema.json

└─ invoice-line.schema.json

└─ credit.schema.json

└─ order.schema.json

└─ settlement.schema.json

182. Event 추가

대표 Event:

subscription.created

subscription.updated

subscription.cancelled

entitlement.granted

entitlement.revoked

usage.recorded

quota.exceeded

budget.warning

invoice.created

invoice.paid

marketplace.order.completed

settlement.created

183. Permission 추가

예:

billing:read

billing:manage

subscription:read

subscription:manage

entitlement:read

entitlement:grant

usage:read

invoice:read

invoice:adjust

marketplace-order:create

settlement:read

entitlement:grant 같은 권한은 매우 높은 Privileged Permission으로 관리한다.

184. Audit 추가

특히:

manual entitlement grant

invoice adjustment

credit issuance


subscription backdate


price override

settlement override

는 반드시 사유를 기록한다.

185. Billing과 AGEX 전체 Architecture 연결







Invoice

186. 핵심 기술 명제

명제 1

구매했다고 실행 권한이 생기는 것은 아니다.

명제 2

사용했다고 반드시 같은 단위로 과금할 필요는 없다.

명제 3

Runtime Meter와 Customer Pricing Meter는 분리할 수 있다.

명제 4

Usage는 변경하지 않고 Adjustment로 정정한다.

명제 5

Security 상태와 Commercial 상태는 절대 동일 상태 머신으로 관리하지 않는다.

명제 6

AGEX의 수익모델은 Token 재판매가 아니라 Platform·Runtime·Governance·Ecosystem 가치에 기반해야 한다.

187. AGEX Commercial Resource 관계

Product



Plan



Price



Offer



Subscription



Entitlement

Marketplace:

Package



Listing



Offer



Order



Entitlement



Installation

Runtime:

Execution



Usage



Meter



Rating

↓
Ledger
↓
Invoice

188. 개발 우선순위

Core 개발에서는 Billing 때문에 Runtime 구현을 늦추지 않는다.

순서:

Phase A

- UsageRecord
- Meter 기본
- Entitlement
- Plan/Subscription 최소

Phase B

- Quota
- Budget
- Usage Dashboard

Phase C

- Rating
- Ledger
- Invoice

Phase D

- Managed Model Billing
- Enterprise Contract

Phase E

- Marketplace Order
 - Publisher Settlement
-

189. 최종 정의

AGEX Billing & Entitlement Architecture는 결제 수단을 연결하고 월 사용료를 계산하는 부가 시스템이 아니다.

AGEX가 실제 SaaS, Enterprise Platform, Dedicated Runtime, Private Deployment 및 Marketplace 사업으로 확장되기 위해서는 Platform Capability를 누가 계약상 사용할 수 있는지, 실제 사용량이 얼마나 발생했는지, 그것을 어떤 가격 규칙으로 금액화할지, 그리고 상업적 권리와 기술적 Permission을 어떻게 분리할 것인지가 명확해야 한다.

Subscription은 Tenant와 Commercial Plan의 관계를 표현하고, Entitlement는 그 계약으로 인해 사용할 수 있는 Product Capability를 표현한다. 그러나 Entitlement는 Security Permission을 생성하지 않으며 모든 실제 Action은 IAM과 Policy를 별도로 통과해야 한다.

실제 Runtime·Model·Plugin·Knowledge·Storage 사용량은 변경 불가능한 Usage Record로 기록하고 Meter와 Rating을 통해 Billing Ledger로 변환한다. 이미 확정된 Usage나 Ledger를 직접 수정하지 않고 Adjustment를 통해 정정함으로써 청구 결과를 재현하고 Audit할 수 있어야 한다.

BYOK, AGEX Managed Model, Private Model 및 Dedicated Runtime은 서로 다른 Cost Structure를 가지므로 동일한 Token 기반 과금 방식으로 강제하지 않는다.

Marketplace에서는 Package, Listing, Offer, Order, Entitlement, Installation을 분리하여 구매가 곧 실행 권한이 되는 구조를 방지하고 Publisher Settlement까지 추적 가능한 Commercial Chain을 유지한다.

Billing Restriction은 Security Suspension과 다른 상태이며 결제 문제 때문에 Security 의미를 오염시키지 않는다. 반대로 Security Incident가 발생하면 Subscription 상태와 관계 없이 Security Control이 최우선한다.

본 문서는 다음 문장으로 최종 정의한다.

AGEX Billing & Entitlement Architecture는 AGEX의 Platform Capability를 계약 가능한 권리로 정의하고, 실제 AI 실행과 Resource 사용을 감사 가능한 Usage·Meter·Ledger 구조로 전환하여 Subscription·Usage·Enterprise·Marketplace 수익모델을 안정적으로 운

영하되 Commercial 권리와 Security 권한을 끝까지 분리하는 AI Operating System의 공식 상용화 제어 체계이다.