

AGEX Model Gateway / Model Router Architecture

1. 문서 개요

1.1 문서 목적

본 문서는 AGEX에서 사용되는 모든 AI Model Provider와 Model을 하나의 공통 Contract로 추상화하고, Agent·Workflow·Application·Runtime이 특정 Provider에 종속되지 않도록 하는 **Model Gateway 및 Model Router의 공식 Architecture와 실행 규칙**을 정의한다.

AGEX의 Agent 또는 Workflow는 OpenAI, Anthropic, Gemini, xAI, OpenRouter, Private Model Runtime 등 특정 Provider를 직접 호출하지 않는다.

모든 Model Request는 다음 경로를 사용한다.

Agent / Workflow / Application

↓

AGEX Model Gateway

↓

Model Router

↓

Provider Adapter

↓

Model

본 문서는 다음 항목을 공식화한다.

- Provider Resource
- Model Resource
- Model Profile
- Provider Trust Class
- Model Capability
- Routing Policy
- Data Classification

- Region / Residency
- Security
- Cost
- Latency
- Quality
- Provider Health
- Rate Limit
- Fallback
- BYOK
- Private Model
- Aggregator Provider
- Structured Output
- Tool Calling
- Streaming
- Embedding
- Reranking
- Usage Metering
- Audit
- Evaluation
- Failure Handling
- Runtime Integration

본 문서는 AGEX Agent Framework, Runtime Architecture, Security Architecture, Multi-Tenant Architecture, API Specification, SDK 및 Canonical Resource & Schema Specification과 함께 사용한다.

2. 공식 정의

AGEX Model Gateway는 다양한 AI Model Provider와 Model을 공통 Platform Contract로 추상화하고, Security·Data Classification·Tenant Policy·Capability·Region·Quality·Health·Latency·Cost를 기준으로 적절한 Model을 선택하여 실행하는 AGEX의 공식 AI Model Access Layer이다.

Model Gateway와 Model Router는 동일한 개념이 아니다.

Model Gateway

외부 및 Private Model 접근의 전체 Control Boundary.

Model Router

Gateway 내부에서 실제 Model을 선택하는 Decision Component.

3. Architecture 목표

Model Gateway는 다음을 달성해야 한다.

1. Agent를 Provider 구현에서 분리한다.
2. Model 변경 시 Agent 코드 수정 범위를 최소화한다.
3. Provider별 API 차이를 공통 Contract로 정규화한다.
4. Data Classification에 따라 사용할 수 있는 Provider를 제한한다.
5. Tenant별 Model Policy를 적용한다.
6. Region 및 Data Residency를 보장한다.
7. 장애 시 승인된 Fallback을 수행한다.
8. Model Health를 Routing에 반영한다.
9. Cost와 Usage를 Execution에 귀속한다.
10. Structured Output을 검증한다.
11. Tool Calling을 공통 Action Candidate로 변환한다.
12. Streaming Event를 표준화한다.
13. BYOK와 AGEX Managed Credential을 모두 지원한다.
14. Private Model을 외부 Provider와 동일한 Contract로 사용할 수 있게 한다.


15. Provider 또는 Model이 Security Authority가 되지 않도록 한다.



4. 설계 원칙

AGEX Model Gateway는 다음 원칙을 따른다.

- Model Agnostic
 - Provider Agnostic
 - Security Before Cost
 - Data Policy Before Availability
 - Tenant Policy Before Preference
 - Explicit Capability
 - Explicit Trust
 - Versioned Model Metadata
 - Provider Adapter Isolation
 - Fail-Safe Routing
 - Policy-Governed Fallback
 - Usage Observable
 - Cost Aware
 - Health Aware
 - Structured Output Validation
 - Tool Call Validation
 - No Provider Credential in Agent Context
 - No Direct Provider Call from Application
 - No Hidden Fallback
 - No Security Downgrade for Availability
-

5. 전체 Architecture





6. Model Gateway의 책임

Model Gateway는 다음을 담당한다.

- Authentication to Provider
- Request Normalization
- Model Capability Matching
- Security Policy Evaluation
- Provider Trust Filtering
- Region Filtering
- Routing
- Fallback
- Rate Limit Handling
- Usage Metering

- Response Normalization
 - Structured Output Validation
 - Tool Call Normalization
 - Streaming Normalization
 - Audit
 - Health Tracking
-

7. Model Gateway가 담당하지 않는 것

Model Gateway는 다음을 담당하지 않는다.

- Agent Goal 판단
- Workflow 분기 결정
- Tool 실제 실행
- Agent Permission 결정
- User Authentication
- Knowledge Retrieval
- Memory Retrieval
- Business Logic

이 기능은 각각 다른 Domain 책임이다.

8. Model Provider Resource

Provider는 AI Model을 제공하는 외부 또는 내부 실행 주체다.

예:

- Direct Commercial Provider
- Enterprise Provider
- Aggregator

- Private Model Runtime
- On-Prem Inference Runtime

Provider는 Model과 별도 Resource다.

Provider

└─ Model 1

└─ Model 2

└─ Model 3

9. Provider Resource 기본 구조

개념:

kind: ModelProvider

metadata:

id: prv_xxx

scope_type: PLATFORM

specification:

provider_type: DIRECT

provider_class: DIRECT_APPROVED

endpoint: ...

credential_ref: sec_xxx

regions:

- KR

- US

status:

health: HEALTHY

10. Provider Type

대표 Type:

DIRECT

AGGREGATOR

PRIVATE

ENTERPRISE_MANAGED

CUSTOM

11. Provider Class

공식 Trust Class:

PRIVATE

DIRECT_APPROVED

ENTERPRISE_APPROVED

AGGREGATOR

RESTRICTED

BLOCKED

Provider Type과 Provider Class는 다르다.

예:

DIRECT Provider가 RESTRICTED Class일 수도 있다.

12. Provider Class 의미

PRIVATE

조직 또는 Tenant가 통제하는 Private Runtime.

DIRECT_APPROVED

AGEX가 직접 연결하고 승인한 외부 Provider.

ENTERPRISE_APPROVED

기업 계약 및 별도 보안 요구를 충족한 Provider.

AGGREGATOR

여러 Provider를 중계하는 Aggregator.

RESTRICTED

특정 Data/Use Case에서만 제한적으로 사용.

BLOCKED

사용 금지.

13. BLOCKED Provider

BLOCKED는 어떤 상황에서도 Routing Candidate가 아니다.

다음 상황에서도 사용하지 않는다.

- 모든 다른 Provider 장애
- 가장 저렴함
- 가장 빠름
- User가 명시적으로 요청

Security/Admin 정책 변경 없이는 사용할 수 없다.

14. Provider Scope

Provider는 다음 Scope를 가질 수 있다.

PLATFORM

Platform 공용 Provider.

TENANT

특정 Tenant가 등록한 BYOK 또는 Private Provider.

TENANT Provider는 다른 Tenant에서 사용할 수 없다.

15. BYOK Provider

BYOK는 Tenant가 자신의 Provider Credential을 사용하는 방식이다.

구조:

Tenant

→ Provider Configuration

→ Secret Reference

→ Model Gateway

→ Provider

Credential은 Agent나 Application에 전달되지 않는다.

16. AGEX Managed Provider

AGEX가 Provider Account를 관리하는 방식이다.

Tenant는 Model Gateway를 사용하고 실제 Credential을 알 필요가 없다.

Usage와 Cost는 Tenant Execution에 귀속한다.

17. Hybrid Model

Tenant는 다음을 함께 사용할 수 있다.

- BYOK
- AGEX Managed
- Private Model

Router가 Policy에 따라 선택한다.

18. Provider Credential

Provider Resource에는 Secret Value를 저장하지 않는다.

```
{  
  "credential_ref": "sec_123"  
}
```

실제 호출 시 Credential Broker가 Resolve한다.

19. Provider Endpoint

Private 또는 Custom Provider의 경우 Endpoint를 정의할 수 있다.

외부 입력으로 Endpoint를 임의 변경하지 않는다.

SSRF 및 Network Policy 검증을 적용한다.

20. Provider Region

Provider가 처리 가능한 Region을 명시한다.

예:

KR

JP

US

EU

Region 정보는 Routing에 사용한다.

21. Model Resource

Model은 실제 호출 가능한 AI Capability를 표현한다.

Model은 Provider 하위에 등록된다.

기본 관계:

Provider

→ Model

22. Model Resource 기본 구조

kind: Model

metadata:

id: mdl_xxx

scope_type: PLATFORM

specification:

provider_id: prv_xxx

external_model_id: model-name

capabilities:

- TEXT_GENERATION

- STRUCTURED_OUTPUT

- TOOL_CALLING

context_window: 128000

streaming: true

status:

state: ACTIVE

health: HEALTHY

23. Model ID와 External Model ID

구분:

AGEX Model ID

mdl_xxx

AGEX 내부 불변 Resource ID.

External Model ID

Provider가 사용하는 실제 Model 이름.

Provider 이름이 변경되어도 AGEX Model ID는 유지할 수 있다.

24. Model Capability

공식 Core Capability:

TEXT_GENERATION

STRUCTURED_OUTPUT

TOOL_CALLING

STREAMING

VISION

EMBEDDING

RERANKING

향후 확장 가능:

- AUDIO_INPUT
- AUDIO_OUTPUT
- VIDEO_INPUT
- IMAGE_GENERATION
- CODE_EXECUTION_ASSISTED

단, 새로운 Capability는 Canonical Glossary 및 Schema에 등록한다.

25. Capability 검증

Provider가 "지원한다"고 선언한 것만으로 Capability를 확정하지 않는다.

AGEX Evaluation/Test를 통해 다음을 검증할 수 있다.

- Structured Output 정확성
- Tool Call 형식
- Streaming 동작
- Context Limit
- Embedding Dimension

26. Model Input Modality

예:

TEXT

IMAGE

AUDIO

VIDEO

Model마다 지원 Modality를 명시한다.

27. Model Output Modality

예:

TEXT

JSON

IMAGE

AUDIO

EMBEDDING

28. Context Window

최대 Context Window Metadata를 관리한다.

단, Provider가 표시한 최대값과 실제 Production Policy Limit을 구분한다.

예:

provider_max_context

platform_max_context

tenant_max_context

Effective Limit은 가장 낮은 값을 사용한다.

29. Model Profile

Model Profile은 Agent/Workflow가 직접 Model을 지정하지 않고 요구사항과 Routing Rule을 정의하기 위한 Resource다.

30. Model Profile 예

kind: ModelProfile

specification:

required_capabilities:

- STRUCTURED_OUTPUT
- TOOL_CALLING

allowed_provider_classes:

- PRIVATE
- DIRECT_APPROVED

region_constraints:

- KR

quality_profile: HIGH

latency_profile: STANDARD

fallback_policy:

enabled: true

31. 왜 Model Profile이 필요한가

Agent에 다음을 직접 넣는 방식:

provider = X

model = Y

은 Provider Coupling을 만든다.

대신:

필요 Capability

+

Security

+

Quality

+

Cost

를 Model Profile로 정의한다.

32. Model Pinning

재현성이 중요한 경우 특정 Model Version 또는 Model ID를 Pin할 수 있다.

예:

```
preferred_model_id = mdl_123
```

하지만 Security/Health가 이를 강제로 사용할 의무를 만들지는 않는다.

33. Routing Input

Model Router는 최소 다음 정보를 입력으로 받는다.

- Tenant Context
 - Execution ID
 - Agent/Workflow Resource
 - Model Profile
 - Required Capabilities
 - Data Classification
 - Region
 - Security Policy
 - Quality Requirement
 - Latency Preference
 - Cost Budget
 - Provider Health
 - Rate Limit State
-

34. Routing 공식 순서

AGEX의 공식 Routing 순서는 다음으로 고정한다.

1. Required Capability

↓

2. Data Classification

↓

3. Platform Security Policy

↓

4. Tenant Model Policy

↓

5. Region / Residency

↓

6. Provider Trust

↓

7. Resource / Model State

↓

8. Quality Requirement

↓

9. Provider / Model Health

↓

10. Rate Limit / Capacity

↓

11. Latency Preference

↓

12. Cost Budget

↓

13. Selected Model

35. Security Before Cost

이 순서를 공식 규칙으로 한다.

예:

Model A:

- 낮은 가격
- AGGREGATOR

Model B:

- 높은 가격
- PRIVATE

RESTRICTED Data가 Private Model만 허용된다면 Model B를 사용한다.

가격 때문에 Model A로 전환하지 않는다.

36. Data Classification Routing

공식 Data Classification:

PUBLIC

INTERNAL

CONFIDENTIAL

RESTRICTED

예 Policy:

PUBLIC

→ approved providers

INTERNAL

→ direct/private

CONFIDENTIAL

→ direct approved/private

RESTRICTED

→ private only

실제 Policy는 Tenant별로 달라질 수 있다.

37. Classification Inheritance

Model Request에 여러 Data Source가 포함되면 가장 높은 Classification을 적용하는 것을 기본 원칙으로 한다.

예:

PUBLIC + CONFIDENTIAL

→ CONFIDENTIAL

38. Agent가 Classification을 낮출 수 없음

Agent가 다음을 제안해도:

"이 데이터는 민감하지 않으므로 PUBLIC으로 처리"

Runtime/Security Context를 변경할 수 없다.

39. Region / Residency

Tenant 정책:

processing_region = KR

이면 Router는 KR에서 처리 가능한 Model/Provider만 Candidate로 선택한다.

40. Residency와 Fallback

KR Provider 장애 시 US Provider가 정상이어도 Residency Policy가 US를 금지하면 Fallback하지 않는다.

Availability

<

Residency Policy

41. Provider Trust Filtering

Router는 Security 정책에서 허용되지 않는 Provider Class를 Candidate에서 제거한다.

예:

allowed:

PRIVATE

DIRECT_APPROVED

AGGREGATOR:

exclude

42. Resource State Filtering

다음 상태는 기본 Candidate가 아니다.

- BLOCKED
- DEPRECATED if forbidden
- UNAVAILABLE

DEGRADED는 Policy에 따라 사용할 수 있다.

43. Quality Profile

Model Profile은 추상 Quality Level을 사용할 수 있다.

예:

ECONOMY

STANDARD

HIGH

MAXIMUM

이 값은 특정 Provider 이름과 직접 연결하지 않는다.

44. Quality Score

내부 Router는 Evaluation 결과를 기반으로 Model별 Quality Score를 관리할 수 있다.

Score는 Domain/Task Type별로 달라질 수 있다.

45. Task-specific Quality

하나의 Model이 모든 작업에서 같은 품질을 갖는다고 가정하지 않는다.

예:

structured extraction

tool use

long context

coding

vision

별 Evaluation Profile을 둘 수 있다.

46. Latency Profile

예:

LOW_LATENCY

STANDARD

BATCH

Router가 Response Speed를 고려할 수 있다.

47. Cost Profile

Model Cost Metadata를 정규화한다.

최소:

- Input Cost
- Output Cost
- Other Usage Cost

Cost는 Provider Price 변화 때문에 Versioned Metadata 또는 Pricing Snapshot으로 관리하는 것이 좋다.

48. Cost Budget

Execution 또는 Agent에 Budget이 있으면 Router가 이를 고려한다.

단:

budget optimization

이 Security Rule을 우회할 수 없다.

49. Health

Provider와 Model 각각 Health를 가진다.

대표:

HEALTHY

DEGRADED

UNAVAILABLE

UNKNOWN

50. Provider Health와 Model Health

Provider 전체는 HEALTHY여도 특정 Model이 UNAVAILABLE일 수 있다.

둘을 분리한다.

51. Health Check

Health Source:

- Active Probe
- Recent Request Success Rate
- Latency
- Provider Status
- Rate Limit

단일 Health Endpoint만 의존하지 않을 수 있다.

52. Circuit Breaker

Provider Failure가 반복되면 Circuit Breaker를 열 수 있다.

CLOSED

→ OPEN

→ HALF_OPEN

→ CLOSED

53. Rate Limit

Provider별:

- Requests per minute
- Tokens per minute

- Concurrent Request

등을 관리할 수 있다.

54. Rate Limit State

Router는 현재 Capacity를 고려한다.

예:

Model A는 품질이 가장 높지만 Rate Limit에 도달했으면 승인된 대체 Model을 선택할 수 있다.

55. Fallback

Fallback은 자동 Provider Switching이 아니다.

공식 Flow:

Primary Failure

→ Classify Failure

→ Fallback Allowed?

→ Re-run Security Policy

→ Re-run Residency

→ Re-run Provider Trust

→ Select Alternative

56. Fallback을 적용할 수 있는 경우

예:

- Provider Temporary Failure
- Model Unavailable
- Rate Limit

- Timeout

57. Fallback하지 않는 경우

예:

- Security Policy Denied
- Data Classification Violation
- Invalid Request
- Tool Schema Error
- User Permission Error

이 경우 다른 Model을 반복 호출해 우회하지 않는다.

58. Fallback Group

Model들을 사전에 Group으로 구성할 수 있다.

예:

fallback_group = high-quality-tool-use

Group 내부에서도 Security Filtering을 다시 수행한다.

59. Hidden Fallback 금지

Execution Trace에서 실제 사용 Model을 확인할 수 있어야 한다.

Application 요청:

Model Profile X

실제 실행:

Resolved Model Y

Fallback reason Z

를 기록한다.

60. Provider Adapter

Provider Adapter는 Provider별 API 차이를 AGEX Common Contract로 변환한다.

61. Adapter Interface

공통 Interface:

listModels()

getCapabilities()

generate()

stream()

embed()

rerank()

health()

getUsage()

62. Adapter Responsibility

Adapter 담당:

- Request Translation
 - Auth Binding
 - Provider Parameter Mapping
 - Response Mapping
 - Error Mapping
 - Usage Mapping
 - Streaming Mapping
-

63. Adapter가 하지 않는 것

Adapter는 다음을 하지 않는다.

- Agent Permission 결정
 - Tool 실행
 - Security Policy Override
 - Tenant Routing 결정
 - Fallback 결정
-

64. Generate Common Request

개념:

```
{  
  "model_id": "mdl_xxx",  
  "messages": [],  
  "output_schema": {},  
  "tools": [],  
  "parameters": {},  
  "metadata": {}  
}
```

65. Generate Common Response

```
{  
  "content": "...",  
  "structured_output": {},  
  "tool_calls": [],  
  "finish_reason": "COMPLETED",  
}
```

```
"usage": {},  
"provider_metadata": {}  
}
```

66. Provider Metadata

필요한 Provider-specific 정보는 제한적으로 provider_metadata에 포함할 수 있다.
Core Logic이 이 Field에 의존하지 않도록 한다.

67. Structured Output

AGEX는 Structured Output을 Schema Contract로 관리한다.
Provider Native Structured Output을 지원하면 활용한다.
하지만 최종적으로 AGEX 자체 Schema Validation을 수행한다.

68. JSON처럼 보이는 문자열

다음은 Structured Output으로 인정하지 않는다.

```
"{ foo: bar }"
```

Schema를 통과해야 한다.

69. Structured Output Failure

Policy에 따라:

- Repair attempt
- Retry
- Alternate Model
- Fail

을 사용할 수 있다.

무한 JSON repair를 하지 않는다.

70. Tool Calling

Provider별 Tool Calling 형식을 AGEX Action Candidate로 변환한다.

Provider Tool Call

→ Adapter

→ AGEX Action Candidate

71. Tool Calling 이후

Model Gateway가 Tool을 실행하지 않는다.

Flow:

Model Gateway

→ Action Candidate

→ Agent Runtime

→ Schema

→ Permission

→ Policy

→ Approval

→ Tool Runtime

72. Tool Call Schema

Action Candidate 예:

```
{  
  "tool_id": "tool_xxx",  
  "arguments": {},  
}
```

```
"provider_call_id": "..."  
}
```

73. Tool Call Security

Provider가 Tool 이름이나 Argument를 생성했다는 것은 실행 권한이 아니다.

74. Streaming

Provider별 Streaming Event를 공통 AGEX Stream Event로 변환한다.

75. Streaming Event Type

대표:

START

CONTENT_DELTA

STRUCTURED_DELTA

TOOL_CALL_DELTA

USAGE

COMPLETED

ERROR

76. Streaming Tool Call

Tool Call이 Streaming으로 조각나서 오는 경우 Adapter가 완전한 Action Candidate로 조립한 뒤 Runtime으로 넘긴다.

부분 Argument를 실행하지 않는다.

77. Streaming 종료

Streaming Connection 종료와 Execution 완료는 구분한다.

Provider Stream 장애 시 Retry/Fallback 여부를 Runtime과 Gateway가 판단한다.

78. Embedding

Embedding Request도 Model Gateway를 사용할 수 있다.

입력:

- Text/Content
- Model Profile
- Classification

출력:

- Vector
 - Model
 - Dimension
 - Usage
-

79. Embedding Version

Knowledge Index 재현성을 위해 다음을 기록한다.

- Model ID
 - External Model Version
 - Dimension
 - Normalization
 - Generated At
-

80. Embedding Model 변경

Embedding Model을 변경하면 기존 Index와 호환되지 않을 수 있다.

따라서 Knowledge Engine에서 Reindex가 필요할 수 있다.

81. Reranking

Reranker도 Model Resource로 관리할 수 있다.

Capability:

RERANKING

Knowledge Engine이 Model Gateway를 통해 호출한다.

82. Vision Model

Image Data가 포함되는 경우:

- Data Classification
- Modality Capability
- Provider Policy

를 동일하게 적용한다.

83. Private Model

Private Model은 조직이 직접 운영하는 Inference Runtime이다.

예:

Model Gateway

→ Private Provider Adapter

→ Inference Gateway

→ GPU Worker

84. Private Model도 예외 아님

Private Model도 다음을 적용한다.

- Model Registry
- Capability
- Health
- Usage
- Audit
- Evaluation
- Routing Policy

Private라는 이유로 관리되지 않는 Model을 직접 호출하지 않는다.

85. Private Model Endpoint

Private Runtime Endpoint는 Provider Resource에서 관리한다.

Agent Definition에 Endpoint를 넣지 않는다.

86. On-Prem Model

On-Premises 환경에서도 동일 Model Gateway Contract를 유지한다.

Provider Adapter만 환경별로 달라질 수 있다.

87. Aggregator Provider

Aggregator는 여러 외부 Model을 중계한다.

Aggregator를 사용할 경우 최종 Downstream Provider 정보를 알 수 있는 범위와 Data Policy를 별도로 검토해야 한다.

88. Aggregator Trust

Aggregator는 Direct Provider와 동일 Trust로 자동 분류하지 않는다.

기본적으로 별도 AGGREGATOR Class로 관리한다.

89. Aggregator Routing

가능하면 Aggregator에게 자유 Routing을 맡기기보다 AGEX가 허용 Model을 명시적으로 지정한다.

90. BYOK

Tenant BYOK는 다음 정보를 가진다.

- Provider
 - Secret Reference
 - Allowed Models
 - Tenant Scope
 - Usage Policy
-

91. BYOK Secret

Tenant A의 BYOK Secret을 Tenant B Request에 사용할 수 없다.

Cross-Tenant Credential 사용은 Hard Deny다.

92. BYOK Cost

Provider 청구는 Tenant가 직접 부담할 수 있지만 AGEX는 Platform Usage를 별도로 측정한다.

93. Managed Provider Cost

AGEX Managed Provider는 실제 Provider Cost와 Tenant Usage를 연결할 수 있어야 한다.

94. Usage Record

Model Invocation마다 다음을 기록할 수 있다.

tenant_id

execution_id

agent/workflow

model_id

provider_id

input_tokens

output_tokens

cache_tokens

request_count

latency

estimated_cost

95. Usage Idempotency

Retry/Fallback 때문에 동일 Logical Request가 여러 Provider Call을 만들 수 있다.

Usage는 실제 Provider Call과 Logical Execution Cost를 모두 구분해 기록할 수 있어야 한다.

96. Logical Request ID

Model Request에는 고유 Logical Request ID를 부여할 수 있다.

model_request_id

Fallback Call들은 동일 Logical Request의 Attempt로 연결한다.

97. Model Attempt

예:

Request mdlreq_1

|— Attempt 1: Provider A → timeout

└— Attempt 2: Provider B → success

Cost는 둘 다 발생할 수 있으므로 모두 기록한다.

98. Audit

중요 Audit:

- Provider Registered
 - Provider Trust Changed
 - Model Registered
 - Model Activated
 - Model Blocked
 - Routing Policy Changed
 - BYOK Credential Changed
 - Fallback
 - Restricted Data Routing Decision
-

99. Routing Decision Record

구조화된 Record:

request_id

tenant_id

required_capabilities

classification

candidate_models

excluded_models + reason

selected_model

fallback_from

policy_ids

민감 Prompt Content는 필요하지 않다.

100. Observability

필수 Metric:

- Requests
- Success Rate
- Failure Rate
- Latency
- Token Usage
- Cost
- Provider Health
- Model Health
- Fallback Rate
- Rate Limit
- Structured Output Failure
- Tool Call Failure

101. Model Gateway Trace

Execution Trace

→ Model Request

→ Router Decision

→ Provider Attempt

→ Model Response

전체 AGEX Trace와 연결한다.

102. Logging 금지

다음은 일반 Log에 저장하지 않는다.

- Provider API Key
 - Full Prompt
 - Sensitive Knowledge Context
 - Private Memory
 - Raw Chain-of-Thought
-

103. Prompt 저장 정책

Debugging 목적으로 Prompt 저장이 필요할 경우 별도의 Classification, Masking, Retention 및 Access Policy가 필요하다.

기본 Logging은 Metadata 중심으로 한다.

104. Model Evaluation

Model 등록 시 다음을 평가할 수 있다.

- Capability
- Quality
- Structured Output
- Tool Calling
- Safety
- Latency
- Cost

105. Evaluation 결과

Model별 단일 점수보다 Task Category별 Profile을 유지하는 것이 좋다.

예:

tool_use = 0.92

structured_output = 0.95

long_context = 0.81

106. Model Admission Lifecycle

REGISTERED

→ VALIDATING

→ EVALUATING

→ APPROVED

→ ACTIVE

이후:

DEGRADED

UNAVAILABLE

DEPRECATED

BLOCKED

107. REGISTERED

Metadata만 등록된 상태.

Production Routing 금지.

108. VALIDATING

- Endpoint
- Credential
- Capability
- Response Contract

검증.

109. EVALUATING

품질/안전/성능 Evaluation 수행.

110. APPROVED

Governance/Security 검토 통과.

아직 Router에 Active Candidate가 아닐 수 있다.

111. ACTIVE

Production Routing 가능.

112. DEGRADED

성능 또는 안정성 문제.

Policy에 따라 계속 사용할 수 있다.

113. UNAVAILABLE

신규 Request Candidate에서 제외.

114. DEPRECATED

Migration 대상.

새 Agent Profile에서 사용 제한 가능.

115. BLOCKED

보안/정책상 사용 금지.

116. Model Profile Lifecycle

Model Profile도 Versioned Resource로 관리한다.

Agent Version은 특정 Model Profile Version을 Snapshot에 저장한다.

117. Profile 변경

Model Profile 변경은 실행 결과에 큰 영향을 줄 수 있다.

따라서 Published Profile을 직접 수정하지 않는다.

새 Version을 만든다.

118. Dynamic Health 정보

Model Resource Specification의 Version과 Health Status는 구분한다.

Health는 Runtime Status다.

119. Router Determinism

동일 조건에서도 Load/Health/Cost 변화로 Model이 달라질 수 있다.

재현이 필요한 실행에서는 선택 결과를 Execution Snapshot/Trace에 반드시 기록한다.

120. Deterministic Mode

필요 시 특정 Model Pinning + Fallback Disabled Profile을 제공할 수 있다.

용도:

- Evaluation
 - Compliance
 - Reproduction
-

121. Routing Strategy

지원 가능한 내부 Strategy:

- Fixed
- Priority
- Weighted
- Quality First
- Cost Optimized
- Latency Optimized
- Balanced

단, 모두 Security Filter 이후에 적용한다.

122. Fixed Routing

특정 Model만 사용.

Fallback Disabled 또는 명시적 Group만 허용.

123. Priority Routing

우선순위 Model 순서대로 선택.

124. Weighted Routing

A/B Testing이나 Controlled Rollout에 사용할 수 있다.

Security/Region이 동일하게 충족되는 Candidate에 한정한다.

125. Cost Optimized

허용 Candidate 중 Cost가 낮은 Model을 우선한다.

126. Quality First

Evaluation Quality가 높은 Model을 우선한다.

127. Balanced

Quality, Latency, Cost를 Weighted Score로 결합할 수 있다.

128. Weighted Score 주의

Score 공식은 Router 내부 구현 세부일 수 있다.

그러나 Security/Residency는 Score 요소가 아니라 **Hard Constraint**다.

129. Model Gateway API

대표 내부/공식 API:

POST /model-executions

GET /models

GET /model-profiles

POST /model-profiles

실제 Endpoint는 API Specification에 맞춘다.

130. Internal Runtime API

Agent Runtime은 더 낮은 수준의 Internal Model Gateway Contract를 사용할 수 있다.

Public API와 동일 인증 규칙이 필요하지만 Workload Identity 기반일 수 있다.

131. SDK

SDK는 Provider SDK가 아니라 AGEX Model Client를 제공한다.

예:

```
await agex.models.generate({  
  profileId: "mdp_123",  
  input: ...  
});
```

132. Provider Adapter SDK

외부 개발자가 Provider를 추가할 경우 공식 Model Adapter SDK를 사용한다.

133. Adapter Registration

Adapter가 Code에 존재한다고 자동 사용 가능하지 않다.

Adapter Installed

→ Provider Registered

→ Model Registered

→ Evaluation

→ Approved

→ Active

134. Custom Provider

Enterprise가 자체 LLM Endpoint를 연결할 경우에도 동일 과정 적용.

135. Runtime Integration

Agent Runtime에서 Model Call Flow:

Agent Action

→ Model Request

→ Gateway

→ Router

→ Provider

→ Response

→ Runtime

→ Agent

136. Workflow Integration

Workflow Model Step도 Model Gateway를 사용한다.

Workflow가 Provider를 직접 호출하지 않는다.

137. Knowledge Integration

Embedding/Reranking도 Model Gateway를 통해 처리할 수 있다.

Knowledge Engine이 Provider Credential을 직접 관리하지 않는다.

138. Application Integration

Application Layer가 모델만 직접 쓰고 싶어도 Model Gateway API를 사용한다.

139. Direct Provider Call 금지

다음은 공식적으로 금지한다.

Agent

→ OpenAI SDK directly

Workflow

→ Provider REST API

Application

→ Tenant Provider Key

AGEX Core 기반 Application에서는 Model Gateway를 사용한다.

140. Exception

특정 Provider SDK가 Model Adapter 내부에서 사용되는 것은 허용한다.

즉:

Provider Adapter

→ Provider SDK

는 정상이다.

141. Failure Model — Provider Timeout

Provider Timeout

→ Mark Attempt Failed

→ Health Update

→ Fallback Policy

→ Alternative Candidate

142. Failure Model — Rate Limit

Rate Limit

→ Retry-After

→ Capacity Update

→ Queue/Fallback

143. Failure Model — Invalid Structured Output

Provider Success

→ Schema Validation Fail

→ Repair/Retry/Fallback Policy

144. Failure Model — Tool Call Unsupported

요청 Profile이 Tool Calling을 요구하는데 Model이 지원하지 않으면 Routing Candidate에서 제외한다.

호출 후 발견하는 구조를 최소화한다.

145. Failure Model — Credential Expired

Provider Credential 오류:

- Provider Health Degraded
 - Admin Alert
 - No infinite retry
 - Approved fallback if available
-

146. Failure Model — Policy Denied

Data classification = RESTRICTED

Provider = AGGREGATOR

→ DENY

다른 Aggregator로 Retry하지 않는다.

147. Failure Model — All Models Unavailable

결과:

MODEL_CAPABILITY_UNAVAILABLE

또는:

NO_ELIGIBLE_MODEL

Stable Error Code를 사용한다.

148. Error Code

대표:

MODEL_NOT_FOUND

MODEL_NOT_ACTIVE

MODEL_CAPABILITY_UNAVAILABLE

NO_ELIGIBLE_MODEL

PROVIDER_UNAVAILABLE

PROVIDER_RATE_LIMITED

PROVIDER_AUTH_FAILED

MODEL_TIMEOUT

STRUCTURED_OUTPUT_INVALID

MODEL_POLICY_DENIED

MODEL_REGION_NOT_ALLOWED

149. Security Requirements

Model Gateway는 최소 다음을 보장한다.

1. Provider Credential Isolation
2. Tenant BYOK Isolation
3. Data Classification Enforcement

4. Region Enforcement
5. Provider Trust Enforcement
6. Audit
7. Encryption in Transit
8. Secret Redaction
9. Request Size Limit
10. Abuse/Rate Limit

150. Tenant Isolation

Tenant A의:

- Model Profile
- BYOK Credential
- Private Provider
- Usage

는 Tenant B에서 접근할 수 없다.

151. Provider Data Policy

Provider마다 다음 Metadata를 가질 수 있다.

- Data Retention
- Training Usage
- Residency
- Enterprise Privacy Mode
- Logging Policy

실제 법적/계약적 값은 별도 검증이 필요하다.

152. Policy Engine Integration

Model Gateway는 PDP/Policy Engine으로 다음 Context를 보낸다.

tenant

actor

execution

classification

provider

model

region

action

153. Governance

새 Provider/Model은 Governance Review 대상이다.

특히:

- Aggregator
- External Provider
- New Region
- New Data Handling Policy

는 Security Review가 필요하다.

154. Provider 변경

Provider Trust Class 변경은 고위험 Change다.

예:

DIRECT_APPROVED

→ RESTRICTED

해당 Provider를 사용하는 Model Profile 영향을 분석한다.

155. Model Deprecation 관리

절차:

Deprecated

→ Dependency Discovery

→ Owner Notification

→ Replacement

→ Migration

→ Disable

156. Emergency Model Block

보안 사고 시:

Block Model/Provider

→ Remove from Router

→ Stop new calls

→ Identify affected executions

→ Review fallback

157. Existing Execution

긴 Execution이 이미 Model Snapshot을 가지고 있어도 Emergency Security Block은 Snapshot보다 우선할 수 있다.

158. Model Usage Cache

동일 Prompt/Response Cache를 도입할 경우 매우 신중해야 한다.

Cache Key에는 최소:

- Tenant
- Model
- Model Profile
- Classification
- Input Hash
- Parameters

가 필요할 수 있다.

159. Cross-Tenant Response Cache

Private/Sensitive Model Output을 Cross-Tenant 공유 Cache로 사용하지 않는다.

160. Semantic Cache

향후 비용 최적화를 위해 사용할 수 있지만:

- Privacy
- Tenant
- Classification
- Staleness
- Correctness

검증이 필요하다.

MVP 필수 기능은 아니다.

161. Context Compression

Model Gateway 또는 Context Builder에서 Context Compression을 지원할 수 있다.

하지만 보안 Instruction을 압축 과정에서 제거하거나 변경하지 않는다.

162. Prompt Template Responsibility

Model Gateway는 일반적인 Provider Format Translation을 담당하지만 Agent Instruction 자체의 비즈니스 의미를 재작성하지 않는다.

163. Provider-specific Prompt Conversion

필요한 최소 System/User/Tool Message Mapping만 수행한다.

164. Usage Budget Enforcement

Gateway는 요청 전에 대략적인 Cost Estimate를 계산할 수 있다.

Execution Budget 초과 예상 시 Runtime/Governance에 반환한다.

165. Cost Estimate의 한계

실제 Output Token 수는 호출 전 알 수 없으므로 Estimated Cost와 Actual Cost를 구분한다.

166. Actual Usage

Provider Response에서 실제 Usage가 없는 경우 추정치임을 명시한다.

167. SLA / SLO

Model Gateway 자체 SLO와 Provider SLO를 구분한다.

예:

- Gateway Processing Latency
 - Provider Latency
 - Overall Model Request Latency
-

168. Performance

Gateway Overhead가 Model Latency에 비해 작도록 설계한다.

하지만 Security/Policy Validation을 제거하여 최적화하지 않는다.

169. Horizontal Scaling

Gateway 자체는 가능한 Stateless하게 설계한다.

State:

- Model Registry
- Provider Status
- Routing Policy
- Usage

는 외부 Store에 둔다.

170. Router Cache

Model/Profile Metadata를 Cache할 수 있다.

Policy/Blocked 상태 변경은 빠르게 반영되어야 한다.

Security Block은 Cache TTL보다 우선하도록 Invalidation이 필요하다.

171. Multi-Region Gateway

Data Plane Region마다 Model Gateway Instance를 둘 수 있다.

Tenant 요청은 해당 Region의 Gateway로 Routing한다.

172. Private Deployment

Private Deployment에서는:

Local Model Gateway

→ Local Private Models

→ Optional approved external providers

형태로 구성할 수 있다.

173. Air-Gapped Deployment

외부 Internet이 없는 환경에서는 Private Provider만 Registry에 활성화할 수 있다.

동일 Model Gateway API는 유지한다.

174. Testing

필수 Test:

- Capability Match
- Trust Filter
- Classification Filter
- Region Filter
- Health Filter
- Rate Limit
- Routing Priority
- Fallback
- BYOK Isolation
- Structured Output
- Tool Call
- Streaming
- Cost Metering

175. Security Test

특히:

Tenant A BYOK

→ Tenant B request

→ DENY

RESTRICTED Data

→ AGGREGATOR

→ DENY

BLOCKED Provider

→ Fallback candidate

→ DENY

176. Contract Test

각 Provider Adapter는 공통 Test Suite를 통과해야 한다.

177. Golden Evaluation

동일 Evaluation Dataset으로 Provider/Model 간 비교가 가능해야 한다.

178. Canary

신규 Model은 일부 허용 Traffic에서 Canary로 사용한 뒤 확대할 수 있다.

179. Weighted Rollout

예:

Model A 90%

Model B 10%

동일 Security Profile을 충족하는 경우에만 허용.

180. Rollback

신규 Model 문제 시 Routing Profile을 이전 Version으로 되돌린다.

181. MVP 범위

AGEX MVP Model Gateway는 최소 다음을 구현한다.

- Provider Registry
- Model Registry
- Model Profile
- Provider Adapter Interface
- Direct Provider Adapter 1개 이상
- Private/Mock Provider
- Capability Routing
- Tenant Policy
- Data Classification Filter
- Health
- Basic Fallback
- Usage
- Structured Output
- Tool Calling
- Streaming

182. MVP에서 후순위

- Complex Weighted Routing
- Semantic Cache

- Advanced Cost Optimization
 - Multi-Armed Bandit
 - Autonomous Model Selection Learning
 - Complex Aggregator Routing
 - Cross-region performance optimization
-

183. MVP End-to-End Scenario

Tenant

- Agent v1
 - Model Profile v1
 - Requires STRUCTURED_OUTPUT
 - Classification INTERNAL
 - Router
 - DIRECT_APPROVED Model
 - Adapter
 - Provider
 - Structured Response
 - Schema Validation
 - Usage
 - Agent
-

184. Fallback Scenario

Primary Model

- Provider Timeout
- Circuit Breaker

- Router Re-evaluation
 - Security/Region Check
 - Secondary Approved Model
 - Success
-

185. Restricted Data Scenario

Agent

- RESTRICTED Context
 - Model Profile allows several providers
 - Router applies Data Policy
 - PRIVATE models only
 - Private Model selected
-

186. BYOK Scenario

Tenant A

- Tenant Model Profile
 - Tenant BYOK Provider
 - Secret Reference
 - Credential Broker
 - Provider
 - Usage attributed to Tenant A
-

187. Private Model Scenario

Agent

- Model Gateway

→ Private Provider Adapter

→ Local Inference Gateway

→ GPU Pool

→ Result

Agent Code는 외부 Provider 호출과 동일하다.

188. Model Gateway와 다른 Domain의 경계

Agent

무엇이 필요한지 요청.

Workflow

Model Step 또는 Agent 실행 조정.

Runtime

실행 Lifecycle/Retry/Timeout 관리.

Model Gateway

Model 선택 및 호출.

Security

사용 가능한 Provider/Data Policy 결정.

Governance

Model Admission/Risk/Approval 결정.

Usage

호출량과 비용 기록.

189. Canonical Resource 연결

본 문서는 다음 Resource를 공식 사용한다.

ModelProvider

Model

ModelProfile

ModelRequest

ModelAttempt

ModelUsage

구체 Machine-readable Schema는 Canonical Schema Repository에 작성한다.

190. ModelRequest

논리 구조:

```
{  
  "request_id": "mdr_123",  
  "tenant_id": "ten_123",  
  "execution_id": "exe_123",  
  "profile_id": "mdp_123",  
  "required_capabilities": [],  
  "classification": "INTERNAL",  
  "input": {},  
  "output_schema": {}  
}
```

191. ModelAttempt

```
{  
  "attempt_id": "mda_123",  
  "request_id": "mdr_123",  
  "model_id": "mdl_123",
```

```
"provider_id": "prv_123",  
"attempt_number": 1,  
"state": "COMPLETED"  
}
```

192. ModelAttempt State

CREATED

RUNNING

COMPLETED

FAILED

TIMED_OUT

CANCELLED

193. Model Usage

각 Attempt마다 실제 Usage를 저장한다.

Fallback Call Cost도 누락하지 않는다.

194. Model Gateway Acceptance Criteria

최소 다음을 만족해야 한다.

1. Provider와 Model이 분리된다.
2. Model Profile이 존재한다.
3. Agent가 Provider를 직접 참조하지 않아도 된다.
4. Capability Routing을 지원한다.
5. Data Classification을 적용한다.
6. Provider Trust를 적용한다.

7. Region/Residency를 적용한다.
8. Health를 Routing에 반영한다.
9. Cost를 Security보다 우선하지 않는다.
10. Fallback에서 Security를 재검증한다.
11. BYOK를 Tenant Scope로 격리한다.
12. Private Model을 지원한다.
13. Provider Adapter Contract가 존재한다.
14. Structured Output을 검증한다.
15. Tool Call을 Action Candidate로 정규화한다.
16. Tool을 직접 실행하지 않는다.
17. Streaming을 공통 Event로 정규화한다.
18. Embedding/Reranking을 지원할 수 있다.
19. Usage를 Execution에 귀속한다.
20. Routing Decision을 추적할 수 있다.
21. BLOCKED Provider를 사용할 수 없다.
22. Emergency Block이 실행 Snapshot보다 우선할 수 있다.
23. Tenant Cross-Credential 사용이 불가능하다.
24. Model Admission Lifecycle이 존재한다.
25. Contract Test가 존재한다.

195. 금지사항

다음 Architecture는 허용하지 않는다.

- Agent에서 Provider SDK 직접 호출
- Workflow에서 Provider REST API 직접 호출
- Model Profile 없이 Provider 이름을 모든 Agent에 하드코딩

- Provider와 Model을 하나의 String으로만 관리
- BYOK Secret을 Agent Definition에 저장
- Fallback 시 Security Policy 생략
- 비용이 낮다는 이유로 Restricted Data를 Aggregator에 전송
- BLOCKED Provider를 장애 시 사용
- Model Output을 Permission Decision으로 사용
- Provider Adapter에서 Tool 직접 실행
- Structured Output Validation 생략
- Streaming partial Tool Arguments 실행
- Provider Health를 Agent가 직접 관리
- Application마다 별도 Provider Credential 관리
- Provider Rate Limit에 무한 Retry
- Aggregator가 임의 Model을 선택하도록 무제한 위임
- Private Model을 Registry 외부에서 직접 호출
- Usage/Cost 미측정 Model 호출
- Raw Prompt/Secret을 일반 Log에 저장
- 최신 Model이라는 이유만으로 자동 Production 전환

196. 구현 우선순위

Phase A — Registry

- Provider
- Model
- Model Profile

Phase B — Adapter

- Common Interface

- Generate
- Streaming
- Usage
- Error Mapping

Phase C — Router

- Capability
- Trust
- Region
- Health
- Priority

Phase D — Security

- Data Classification
- Tenant Policy
- BYOK Isolation

Phase E — Runtime

- Retry
- Timeout
- Fallback
- Usage

Phase F — Advanced

- Evaluation Routing
- Cost Optimization
- Weighted Rollout


Agent / Workflow / Application



Model Request




Model Gateway



Security Gate

Model Router




Direct

Aggregator

Private




Provider Adapter Provider Adapter Provider Adapter



Model



Normalized Response



198. 핵심 기술 명제

명제 1

Agent는 Model을 사용하지만 Provider를 알 필요가 없다.

명제 2

Model Router는 가장 좋은 Model을 찾는 기능이 아니라 현재 Security와 Tenant 조건에서 사용할 수 있는 Model 중 가장 적합한 Model을 선택하는 기능이다.

명제 3

Provider 장애는 Security Policy를 완화할 이유가 되지 않는다.

명제 4

Model Output은 판단 Candidate이지 시스템 권한이 아니다.

명제 5

Model Provider가 바뀌어도 Agent·Workflow·Application Contract는 유지되어야 한다.

명제 6

모든 Model Call은 Tenant·Execution·Usage·Audit와 연결되어야 한다.

199. 최종 정의

AGEX Model Gateway / Model Router Architecture는 여러 AI Model을 하나의 API로 묶는 단순 Proxy 구조가 아니다.

AGEX Model Gateway는 AI Model 사용을 Security, Tenant, Data Classification, Region, Provider Trust, Capability, Quality, Health, Latency 및 Cost 기준으로 통제하는 공식 Platform Boundary다.

Agent와 Workflow는 특정 Provider 또는 외부 SDK를 직접 호출하지 않고 필요한 Capability와 Model Policy를 Model Gateway에 전달한다.

Model Router는 요청에 사용 가능한 모든 Model을 대상으로 먼저 Security, Data Classification, Tenant Policy, Residency 및 Provider Trust와 같은 Hard Constraint를 적용하고, 그 이후에 Quality, Health, Latency 및 Cost를 기준으로 최종 Model을 선택한다.

Provider 장애가 발생해도 Fallback은 기존 Security 정책을 우회하지 않으며 모든 대체 Candidate는 다시 전체 Routing Policy를 통과해야 한다.

Provider Adapter는 Provider별 API, Streaming, Structured Output, Tool Calling, Error 및 Usage 차이를 AGEX의 공통 Contract로 변환하지만 Permission, Routing 또는 Tool Execution을 결정하지 않는다.

Private Model, BYOK, Direct Provider 및 Aggregator는 모두 동일한 Model Gateway 계약 안에서 사용되며 Tenant Credential과 Data Boundary가 명확하게 격리된다.

모든 Model Request와 실제 Provider Attempt는 Execution, Tenant, Model, Provider, Usage, Cost 및 Routing Decision에 연결하여 관찰 가능하고 Audit 가능하게 관리한다.

본 문서는 다음 문장으로 최종 정의한다.

AGEX Model Gateway / Model Router는 다양한 AI Model을 단순히 연결하는 Gateway가 아니라, AI Model 사용 자체를 Capability·Security·Tenant·Data·Region·Quality·Health·Cost라는 명시적인 정책 아래 표준화하고 통제하는 AGEX AI Operating System의 공식 Model Execution Control Layer 이다.